

Tekmovanje bicikeLJ

Luka Sabotič

Fakulteta za računalništvo in informatiko, Univerza v Ljubljani

May 29, 2023

Uvod

To poročilo predstavlja analizo predloženega programa za tekmovanje v napovedovanju števila parkiranih koles bicikeLJ postajah v Ljubljani. Tekmovanje je bilo namenjeno razvoju napovednega modela, ki bi pomagal optimizirati razvoj koles iz prepolni na prazne postaje. V tem poročilu opisujem metode in pristope, ki sem jih izbral pri napovedovanju zasedenosti različnih postaj.

Preprocesiranje podatkov

Danim podatkom sem dodal 24 novih atributov: 8 vremenskih in 16 časovnih. Vsi novi atributi so oblikovani po principu *one-hot encoding*-a, torej imajo vrednost 1, če je pogoj zadoščen in 0 sicer. Podatke o vremenu sem dobil z Arsovega spletnega vmesnika.

Vremenske značilke

Nove značilke, ki sem jih ustvaril s pomočjo vremenskih podatkov, spadajo v 3 kategorije:

Padavine Dež je verjetno eden izmed glavnih vplivov na promet z bicikeLJ kolesi. Zanimalo me je, koliko (če sploh) dežuje ob času, ki ga opazujemo, ter če bo kadarkoli tisti dan deževalo. Ker imamo podakte samo iz mesecev avgust in september, sem zanemaril možnost sneženja. Nisem se ukvarjal s točo, ker nevihte s točo ponavadi hitro minejo in se njihove karakteristike dovolj ujemajo z značilko *rain that day*, torej če bo kadarkoli tisti dan deževalo. Preostali dve vremenski značilki sta *light rain* in *heavy rain*. Mejo za njiju sem postavil na 2.5 mm/h, kot se zdi, da se ponavadi uporablja. Če sta obe deževni značilki enaki 0, se smatra, da v tistem trenutku ne dežuje.

Temperatura Temperatura je tudi faktor pri odločanju ali se voziti z bicikeLJ-om, saj nihče ne mara biti prepoten, ko prispe na cilj. Zato sem temperaturo v danem trenutku uvrstil v enega izmed treh razredov: < 20 , $20 - 30$, > 30 . Te so se mi zdele najbolj očitne meje, ko ljudje preverjajo kakšna je zunaj temperatura in se odločajo o prevoznem sredstvu. Morda

se je pri visokih temperaturah bolj udobno voziti s kolesom, kot pa v neklimateziranem avtobusu.

Vlaga Tudi vlaga ima vlogo pri občutku vročine. Naredil sem 2 novi značilki: *low humidity* in *high humidity*, kjer sem mejo postavil na 50%.

Časovne značilke

Sklepal sem na podoben promet skozi vse delovne dni in tako ločil datume na sobote, nedelje in preostale dni. Tako sem dobil značilki *saturday* in *sunday*. Nato sem avgust določil z atributom *school holiday*, saj imajo takrat osnovno in srednješolci počitnice. Značilka, ki opisuje študentsko izpitno obdobje se je na testni lestvici izkazala za slabo. Izločil sem tudi spremenljivko *timestamp* in čas v dnevu nadomestil z *one-hot* predstavitevjo časovnih intervalov. Teh sem naredil 8: *00-03*, *03-07*, *07-09*, *09-12*, *12-15*, *15-17*, *17-20*, *20-24*. Pri določanju teh sem upošteval, da je dogajanje znotraj njih podobno in zajamejo vse tipične dogodke, ki se ponavljajo vsak dan, kot so na primer ure gostega prometa, ure, ko je večina ljudi v službah, čas za malice, večerno zbiranje, odhajanje domov po ponočevanju in podobno.

Podatke sem nato razbil na dataframe za vsako postajo posebej in dodal še 5 informacij o številu koles na posamezni postaji za vsake pol ure pred danim trenutkom, začevši s 60 minut prej, če napovedujemo za 1h vnaprej in 120 minut prej, če napovedujemo za 2h vnaprej.

Model

Modele sem gradil za vsako postajo posebej. Zgradil sem po 2 modela, enega za napovedovanje 1h vnaprej in enega za 2h v prihodnost. Preizkusil sem več različnih modelov, na začetku linearno regresijo, nato pa še Gradient Boosting, Random Forest, SVR in Decision Tree. Po pričakovanjih, se je na testni lestvici najbolje obnesel Gradient boosting, zato je bil to moj končni model. Treniral sem ga s povprečno absolutno napako, ker se ta tudi uporablja za ocenjevanje rezultatov. Vedno sem uporabil enak model za oba, saj sem predvideval, da če je model najboljši za napovedovanje za 1h vnaprej, bo tudi najboljši za 2h in obratno.